NATURAL LANGUAGE PROCESSING

LABORATORY ASSIGNMENT – 02

Fundamental Language Processing for Three Different Languages

Student Name	Shravani Balasaheb Kurkute
Roll No.	421129
PRN / Registration No.	22311926
Class / Division	Btech A
Academic Year	2026-27
Faculty Name	Dr. Kapil N. Vhatkar

Assignment 2: Fundamental Language Processing for Three Different Languages

Aim: Using Python and suitable libraries, perform fundamental Natural Language Processing tasks for three different natural languages and compare the results.

1. Objectives

- Understand basic NLP operations and their application to multilingual text.
- Perform text normalization, sentence segmentation and word tokenization.
- Apply stop-word removal, stemming and/or lemmatization where supported.
- Perform at least one additional NLP task such as POS tagging, NER or frequency analysis.
- Compare processing behavior, resources and language-specific challenges.

2. Problem Statement

Select three different natural languages and collect a suitable text sample for each language. Using Python and appropriate open-source NLP libraries, perform fundamental language-processing operations and compare the outputs, available resources and language-specific challenges.

3. Suggested Languages

Students may select any three languages with suitable NLP resource support. Suggested examples:

- English
- Hindi
- Marathi
- French
- German
- Spanish

Selected Language 1: English Language 2: Hindi Language 3: Marathi

4. Theory / Background

NLP preprocessing converts raw natural language text into a structured form suitable for computational analysis. Common preprocessing operations include normalization, sentence segmentation, word tokenization, stop-word removal, stemming and lemmatization.

In multilingual NLP, preprocessing methods can behave differently depending on the language. English has extensive NLP resources and commonly available tools such as NLTK and spaCy. Hindi and Marathi require language-specific resources because they use the Devanagari script and have different morphological and grammatical characteristics.

Tokenization separates text into meaningful units called tokens. Stop-word removal removes very common words that may not contribute much to certain NLP tasks. Stemming reduces words to simpler root-like forms, while lemmatization attempts to obtain the linguistically correct base form.

For this assignment, **frequency analysis** is used as the additional NLP task. It identifies frequently occurring words in each language and allows comparison of vocabulary usage.

5. Tools, Libraries and Environment

Sr. No.	Tool / Library	Version	Purpose
1	Python	3.x	Programming language
2	Google Colab	Current	Execution environment
3	Pandas	Current	Reading and processing Excel dataset
4	NLTK	Current	English stop words and stemming
5	openpyxl	Current	Reading Excel .xlsx files
6	re / Unicode processing	Python standard library	Tokenization and text normalization

6. Dataset / Text Corpus

Language	Dataset / Corpus	Source	No. of Sentences / Documents	Description
English	NLP Three Languages Dataset	Provided Excel dataset	50	English sentences related to NLP, data science and machine learning
Hindi	NLP Three Languages Dataset	Provided Excel dataset	50	Hindi translations of the English sentences
Marathi	NLP Three Languages Dataset	Provided Excel dataset	50	Marathi translations of the English sentences

7. NLP Processing Pipeline

The following pipeline was used:

1. Read the provided Excel dataset.
2. Select English, Hindi and Marathi columns.
3. Normalize the text.
4. Perform sentence segmentation.
5. Perform word tokenization.
6. Remove punctuation.

7. Remove stop words using language-specific stop-word lists.

8. Apply English stemming using the Porter Stemmer.
9. Do not apply stemming to Hindi and Marathi because the selected basic processing pipeline does not include a validated stemmer for these languages.
10. Perform word-frequency analysis.
11. Compare the results across the three languages.

8. Language-wise Implementation

8.1 Processing for Language 1

Language: English

Input Text / Sample:

I love natural language processing.

Students learn machine learning.

Data science is an interesting field.

Processing performed:

- Lowercase normalization
- Sentence segmentation
- Word tokenization
- Punctuation removal
- Stop-word removal
- Porter stemming
- Frequency analysis

Output/observations: The English sentences were successfully tokenized into individual words. Common English stop words were removed. Porter stemming was applied to the remaining English words.

For example:

Original:

Students learn machine learning.

Tokens:

students, learn, machine, learning

After stop-word removal:

students, learn, machine, learning

The English corpus contained **297 tokens** and **165 unique tokens** before stop-word removal.

8.2 Processing for Language 2

Language: Hindi

Input Text / Sample:

मुझे प्राकृतिक भाषा प्रसंस्करण पसंद है।

छात्र मशीन लतनिंग

सीखि हैं। डेटा तिज्ञान

एक रोचक क्षेत्र है।

Processing performed:

- Unicode text normalization
- Sentence segmentation
- Devanagari word tokenization
- Punctuation removal
- Hindi stop-word removal
- Frequency analysis

Output / observations:

Hindi text was processed using Unicode-aware tokenization. Hindi words were correctly preserved in the Devanagari script.

For example:

Original:

मुझे प्राकृतिक भाषा प्रसंस्करण पसंद है।

Tokens:

मुझे, प्राकृतिक, भाषा, प्रसंस्करण, पसंद, है

Stop words such as मुझे, है, हैं, और and other common Hindi function words were removed where applicable.

The Hindi corpus contained **407 tokens** and **168 unique tokens** before stop-word removal.

8.3 Processing for Language 3

Language: Marathi

Input Text / Sample:

मला नैसतगिक भाषा प्रतिया

आिडे. तिद्यार्थी मशीन

लतनिंग तशकिा.

डेटा सायन्स हे एक मनोरंजक क्षेत्र आहे.

Processing performed:

- Unicode text normalization
- Sentence segmentation
- Devanagari word tokenization
- Punctuation removal
- Marathi stop-word removal
- Frequency analysis

Output / observations: Marathi text was processed using Unicode-aware tokenization. Marathi words were preserved correctly in the Devanagari script.

For example:

Original:

मला नैसतगिक भाषा प्रतिया आिडे.

Tokens:

मला, नैसतगिक, भाषा, प्रतिया, आिडे

Common Marathi stop words were removed where applicable.

The Marathi corpus contained **297 tokens** and **190 unique tokens** before stop-word removal.

9. Comparative Results

Parameter	English	Hindi	Marathi
Tool / Model	NLTK + Python	Python + Unicode processing	Python + Unicode processing
No. of sentences	50	50	50
No. of tokens	297	407	297
No. of unique tokens	165	168	190
Tokens after stop-word removal	220	262	267

Unique tokens after stop-word removal	141	151	180
Stop words removed	Yes	Yes	Yes
Stemming / Lemmatization	Porter stemming	Not applied	Not applied
Additional NLP task	Frequency analysis	Frequency analysis	Frequency analysis
Processing issues	Morphological variants	Devanagari and morphology	Devanagari and morphology

10. Additional NLP Task

Select one: POS Tagging / Named Entity Recognition / Frequency Analysis / Other: Frequency Analysis

Method / Library Used: collections.Counter

Results: The most frequent words after basic stop-word removal were

Rank	English	Frequency	Hindi	Frequency	Marathi	Frequency
1	data	14	डेटा	14	ािपर	8
2	language	7	उपयोग	8	डेटा	7
3	learning	6	भाषा	7	करि	7
4	text	6	पाठ	6	भाषा	6
5	students	5	कर	6	प्रतिया	5
6	model	5	मॉडल	6	तिद्यार्थी	5
7	analysis	4	छात्र	5	कीरिा	4
8	natural	3	तिश्लेषण	5	करू	4
9	processing	3	लतनिंग	4	केला	4
10	machine	3	तकया	4	जिाो	4

11. Source Code

Source Code -

The assignment was implemented in Python using libraries such as Pandas, NLTK, OpenPyXL, and

Matplotlib. The program processes English, Hindi, and Marathi text through normalization, tokenization, punctuation removal, language-specific stop-word removal, and word-frequency analysis. Porter stemming is applied only to English text. The program also generates comparative results, visualizations, and an Excel workbook.

Main Python Implementation

```
import pandas as pd
import unicodedata
import re
from collections import Counter
from nltk.stem import PorterStemmer

# Load the multilingual dataset
df = pd.read_csv("data/NLP_Three_Languages_Dataset.csv")

# Normalize text
def normalize_text(text, language):
    text = unicodedata.normalize("NFC", str(text))
    if language == "English":
        text = text.lower()
    return " ".join(text.split())

# Tokenize text
def tokenize_words(text):
    return re.findall(r"\w+", text, flags=re.UNICODE)

# Calculate word frequencies
def calculate_word_frequencies(tokens):
    return Counter(tokens)

# Apply English stemming
stemmer = PorterStemmer()

def apply_english_stemming(tokens):
    return [stemmer.stem(token) for token in tokens]

# Display dataset information
print("Dataset shape:", df.shape)
```

```
print("Dataset columns:", df.columns.tolist())
```

Note: This is an illustrative excerpt. Use the corresponding functions from your actual `ASG2.py` implementation in the final report.

12. Results / Output Screenshots

```
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$ libreoffice --writer Assignment_02_Report.docx
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$ cd "/home/shravanikurkute/BTech/4th Year/NLP/Assignment 2"
mkdir -p screenshots
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$ cd "/home/shravanikurkute/BTech/4th Year/NLP/Assignment 2"
pwd
python3 ASG2.py
/home/shravanikurkute/BTech/4th Year/NLP/Assignment 2
======================================================================
NLP Laboratory Assignment - 02 : Three-Language Processing Pipeline
======================================================================

[STEP 1] Loading and validating dataset ...
  Columns : ['ID', 'English', 'Hindi', 'Marathi']
  Rows    : 50 (expected 50)
  Missing : {'ID': 0, 'English': 0, 'Hindi': 0, 'Marathi': 0}
  Result  : PASSED

[STEP 2] Processing each language ...
  English  sentences=50  tokens_before=297  unique_before=165  tokens_after=224  unique_after=144  removed=73
           post-stemming tokens=224, unique stems=127
  Hindi    sentences=50  tokens_before=407  unique_before=168  tokens_after=225  unique_after=135  removed=182
  Marathi  sentences=50  tokens_before=297  unique_before=190  tokens_after=242  unique_after=170  removed=55
  Highest post-stop-word vocabulary: Marathi (170 unique tokens).
  Lowest post-stop-word vocabulary: Hindi (135 unique tokens).

[STEP 3] Exporting Excel workbook ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/ASG2_Results.xlsx

[STEP 4] Generating charts ...
  Devanagari status: Pillow+Raqm shaping using NotoSansDevanagari[wght].ttf
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/token_comparison.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/vocabulary_comparison.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/english_top10.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/hindi_top10.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/marathi_top10.png

[STEP 5] Creating DOCX report ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/Assignment_02_Report.docx

[STEP 6] Creating Jupyter notebook ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/ASG2.ipynb

[STEP 8] Running self tests ...
  [PASS] Hindi NFC preserves Devanagari
  [PASS] Hindi normalization is NFC
  [PASS] English lowercasing
  [PASS] Hindi tokenization keeps words whole
  [PASS] Hindi conjunct tokenization
```

```
           post-stemming tokens=224, unique stems=127
  Hindi    sentences=50  tokens_before=407  unique_before=168  tokens_after=225  unique_after=135  removed=182
  Marathi  sentences=50  tokens_before=297  unique_before=190  tokens_after=242  unique_after=170  removed=55
  Highest post-stop-word vocabulary: Marathi (170 unique tokens).
  Lowest post-stop-word vocabulary: Hindi (135 unique tokens).

[STEP 3] Exporting Excel workbook ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/ASG2_Results.xlsx

[STEP 4] Generating charts ...
  Devanagari status: Pillow+Raqm shaping using NotoSansDevanagari[wght].ttf
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/token_comparison.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/vocabulary_comparison.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/english_top10.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/hindi_top10.png
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/visualizations/marathi_top10.png

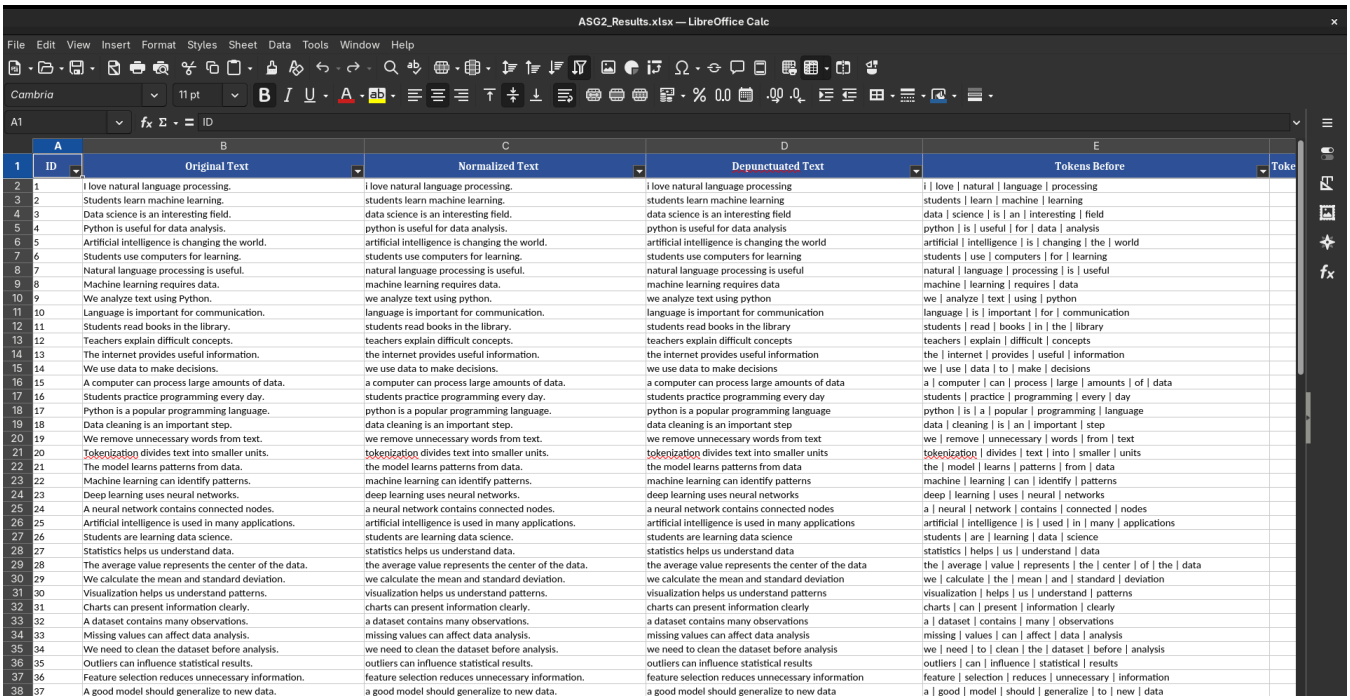
[STEP 5] Creating DOCX report ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/Assignment_02_Report.docx

[STEP 6] Creating Jupyter notebook ...
  Written: /home/shravanikurkute/BTech/4th Year/NLP/Assignment 2/ASG2.ipynb

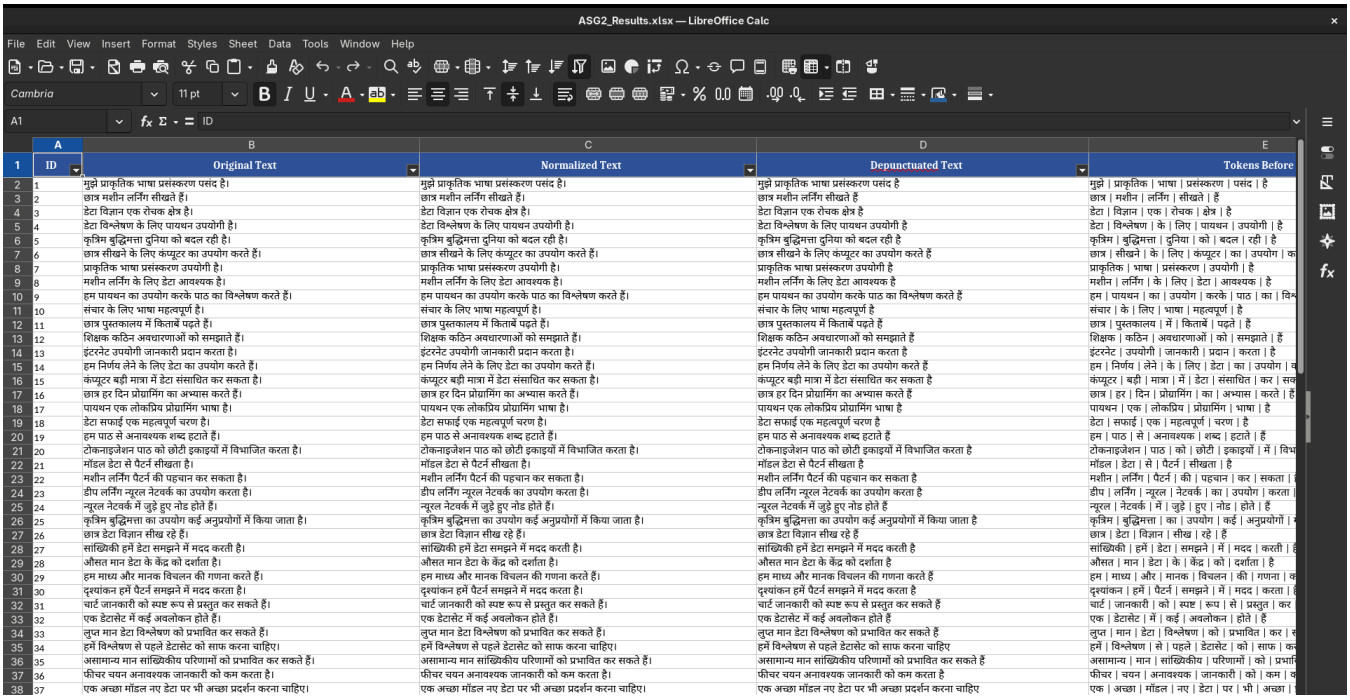
[STEP 8] Running self tests ...
  [PASS] Hindi NFC preserves Devanagari
  [PASS] Hindi normalization is NFC
  [PASS] English lowercasing
  [PASS] Hindi tokenization keeps words whole
  [PASS] Hindi conjunct tokenization
  [PASS] English punctuation removal
  [PASS] Hindi punctuation removal preserves matras
  [PASS] Hindi danda removed before tokenization
  [PASS] English stop-word removal
  [PASS] Hindi stop-word removal
  [PASS] Marathi stop-word removal
  [PASS] Hindi/Marathi stop lists are language-specific
  [PASS] English Porter stemming
  [PASS] Frequency counting
  [PASS] Frequency total equals post-stop-word token count
  [PASS] Unique post-stop tokens equals len(frequency)
  [PASS] English stemming applied to English only
  [PASS] English post-stemming total equals post-stop token count
  [PASS] Devanagari label renders with ink (not blank/tofu)
  Tests: 19 passed, 0 failed

Done.
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$
```

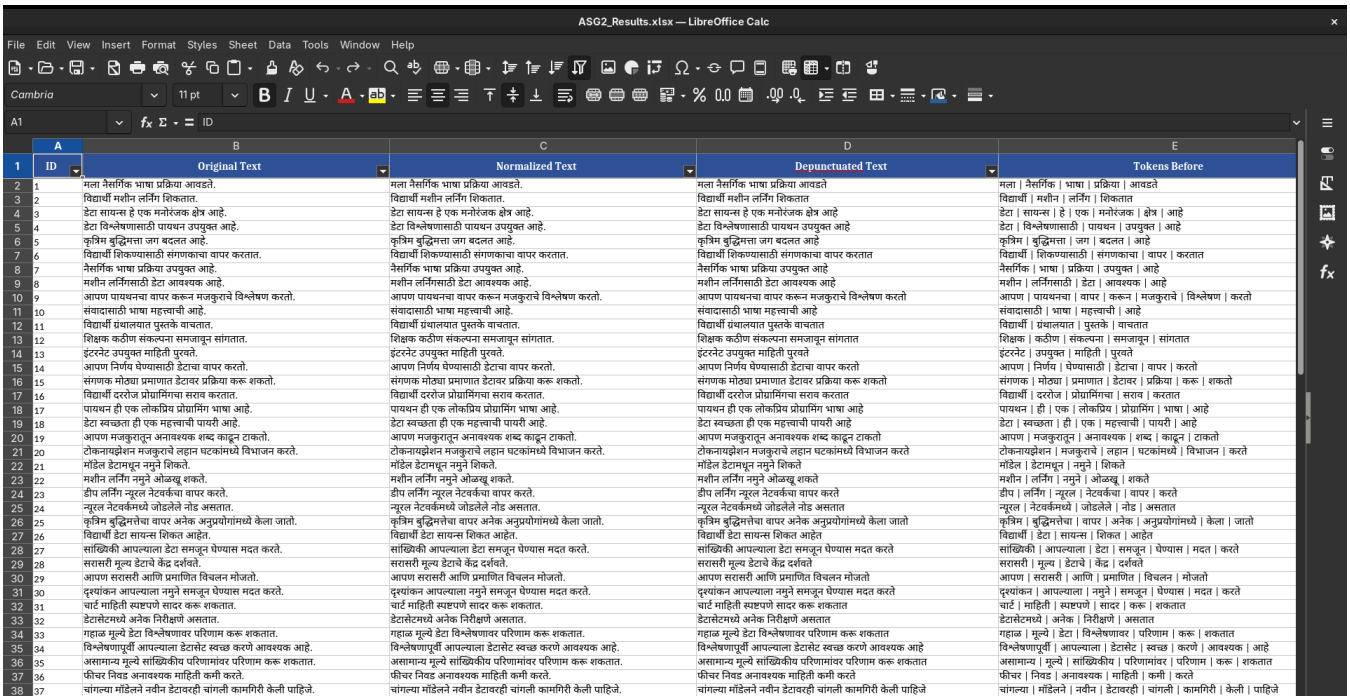
```
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$ python3 -c "import pandas as pd; d=pd.read_csv('data/NLP_Three_Languages_Dataset.csv'); print('Shape:',d.shape); print('Columns:',d.columns.tolist(
)); print('Missing values:'); print(d.isnull().sum()); print(d.head(5).to_string(index=False))"
Shape: (50, 4)
Columns: ['ID', 'English', 'Hindi', 'Marathi']
Missing values:
ID         0
English    0
Hindi      0
Marathi    0
dtype: int64
 ID                                    English                                      Hindi                                    Marathi
  1           I love natural language processing.   मुझे प्रा कृति क भा षा  प्र संस्करण पसंद  है।      मला  नैसर्गि क भा षा  प्र क्रि या  आवडते.
  2              Students learn machine learning.                  छा त्र  मशी न  लर्नि ंग  सी खते  हैं।         वि द्या र्थी  मशी न  लर्नि ंग  शि कत ात.
  3         Data science is an interesting field.          डेटा  वि ज्ञा न  एक रो चक क्षेत्र  है।  डेटा  सा यन्स  हे  एक मनो रंजक क्षेत्र  आहे.
  4           Python is useful for data analysis.     डेटा  वि श्लेषण के लि ए  पा यथन  उपयो गी  है।   डेटा  वि श्लेषणा सा ठी  पा यथन  उपयुक्त  आहे.
  5 Artificial intelligence is changing the world. कृत्रि म बुद्धि मत्ता  दुनि या  को  बदल  रही  है।        कृत्रि म बुद्धि मत्ता  जग  बदलत  आहे.
(base) shravanikurkute@fedora:~/BTech/4th Year/NLP/Assignment 2$
```



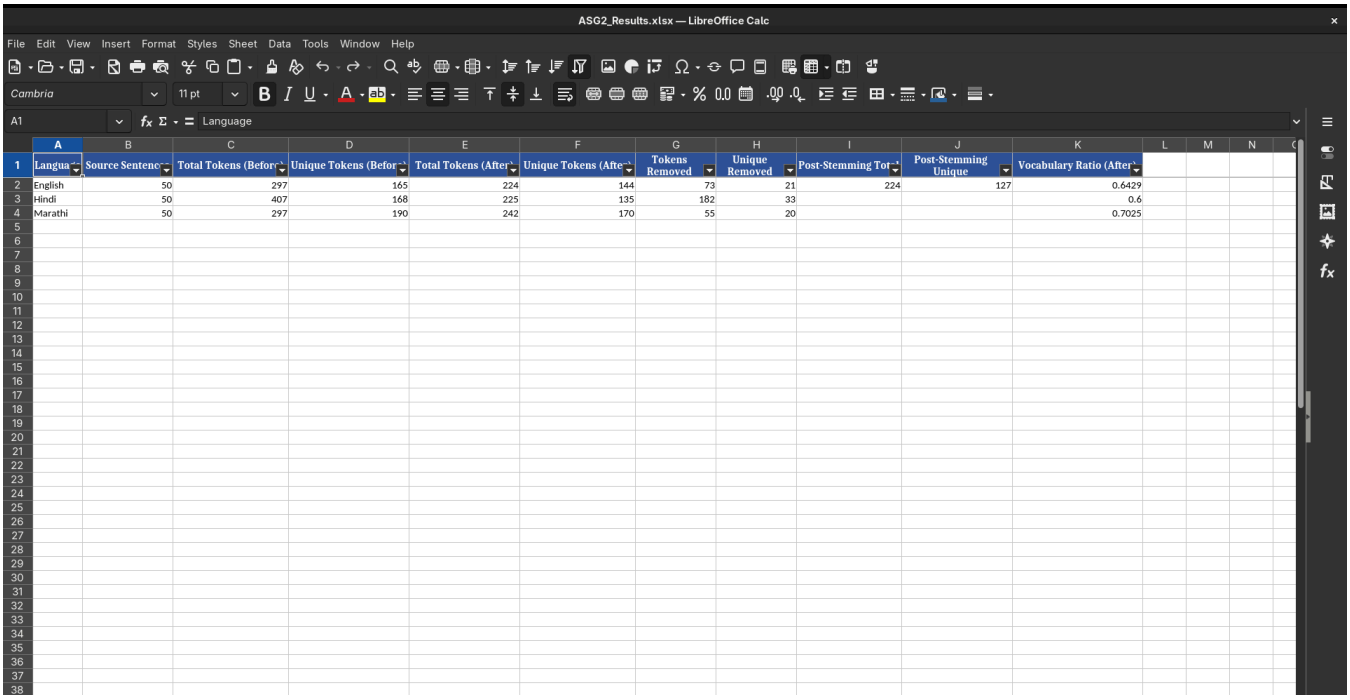
ID	Original Text	Normalized Text	Depunctuated Text	Tokens Before	Toke
1	I love natural language processing.	i love natural language processing.	i love natural language processing	i | love | natural | language | processing	
2	Students learn machine learning.	students learn machine learning.	students learn machine learning	students | learn | machine | learning	
3	Data science is an interesting field.	data science is an interesting field.	data science is an interesting field	data | science | is | an | interesting | field	
4	Python is useful for data analysis.	python is useful for data analysis.	python is useful for data analysis	python | is | useful | for | data | analysis	
5	Artificial intelligence is changing the world.	artificial intelligence is changing the world.	artificial intelligence is changing the world	artificial | intelligence | is | changing | the | world	
6	Students use computers for learning.	students use computers for learning.	students use computers for learning	students | use | computers | for | learning	
7	Natural language processing is useful.	natural language processing is useful.	natural language processing is useful	natural | language | processing | is | useful	
8	Machine learning requires data.	machine learning requires data.	machine learning requires data	machine | learning | requires | data	
9	We analyze text using Python.	we analyze text using python.	we analyze text using python	we | analyze | text | using | python	
10	Language is important for communication.	language is important for communication.	language is important for communication	language | is | important | for | communication	
11	Students read books in the library.	students read books in the library.	students read books in the library	students | read | books | in | the | library	
12	Teachers explain difficult concepts.	teachers explain difficult concepts.	teachers explain difficult concepts	teachers | explain | difficult | concepts	
13	The internet provides useful information.	the internet provides useful information.	the internet provides useful information	the | internet | provides | useful | information	
14	We use data to make decisions.	we use data to make decisions.	we use data to make decisions	we | use | data | to | make | decisions	
15	A computer can process large amounts of data.	a computer can process large amounts of data.	a computer can process large amounts of data	a | computer | can | process | large | amounts | of | data	
16	Students practice programming every day.	students practice programming every day.	students practice programming every day	students | practice | programming | every | day	
17	Python is a popular programming language.	python is a popular programming language.	python is a popular programming language	python | is | a | popular | programming | language	
18	Data cleaning is an important step.	data cleaning is an important step.	data cleaning is an important step	data | cleaning | is | an | important | step	
19	We remove unnecessary words from text.	we remove unnecessary words from text.	we remove unnecessary words from text	we | remove | unnecessary | words | from | text	
20	Tokenization divides text into smaller units.	tokenization divides text into smaller units.	tokenization divides text into smaller units	tokenization | divides | text | into | smaller | units	
21	The model learns patterns from data.	the model learns patterns from data.	the model learns patterns from data	the | model | learns | patterns | from | data	
22	Machine learning can identify patterns.	machine learning can identify patterns.	machine learning can identify patterns	machine | learning | can | identify | patterns	
23	Deep learning uses neural networks.	deep learning uses neural networks.	deep learning uses neural networks	deep | learning | uses | neural | networks	
24	A neural network contains connected nodes.	a neural network contains connected nodes.	a neural network contains connected nodes	a | neural | network | contains | connected | nodes	
25	Artificial intelligence is used in many applications.	artificial intelligence is used in many applications.	artificial intelligence is used in many applications	artificial | intelligence | is | used | in | many | applications	
26	Students are learning data science.	students are learning data science.	students are learning data science	students | are | learning | data | science	
27	Statistics helps us understand data.	statistics helps us understand data.	statistics helps us understand data	statistics | helps | us | understand | data	
28	The average value represents the center of the data.	the average value represents the center of the data.	the average value represents the center of the data	the | average | value | represents | the | center | of | the | data	
29	We calculate the mean and standard deviation.	we calculate the mean and standard deviation.	we calculate the mean and standard deviation	we | calculate | the | mean | and | standard | deviation	
30	Visualization helps us understand patterns.	visualization helps us understand patterns.	visualization helps us understand patterns	visualization | helps | us | understand | patterns	
31	Charts can present information clearly.	charts can present information clearly.	charts can present information clearly	charts | can | present | information | clearly	
32	A dataset contains many observations.	a dataset contains many observations.	a dataset contains many observations	a | dataset | contains | many | observations	
33	Missing values can affect data analysis.	missing values can affect data analysis.	missing values can affect data analysis	missing | values | can | affect | data | analysis	
34	We need to clean the dataset before analysis.	we need to clean the dataset before analysis.	we need to clean the dataset before analysis	we | need | to | clean | the | dataset | before | analysis	
35	Outliers can influence statistical results.	outliers can influence statistical results.	outliers can influence statistical results	outliers | can | influence | statistical | results	
36	Feature selection reduces unnecessary information.	feature selection reduces unnecessary information.	feature selection reduces unnecessary information	feature | selection | reduces | unnecessary | information	
37	A good model should generalize to new data.	a good model should generalize to new data.	a good model should generalize to new data	a | good | model | should | generalize | to | new | data	



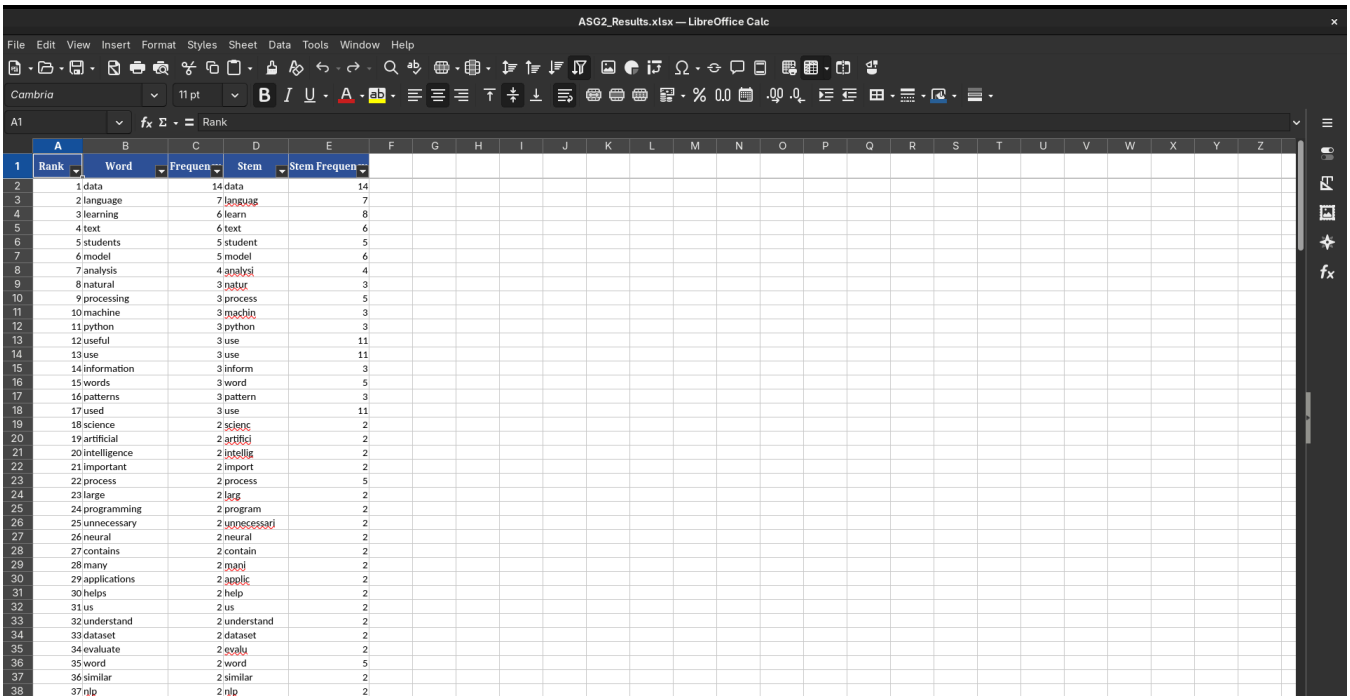
ID	Original Text	Normalized Text	Depunctuated Text	Tokens Before
1	मुझे प्राकृतिक भाषा प्रसंस्करण पसंद है।	मुझे प्राकृतिक भाषा प्रसंस्करण पसंद है।	मुझे प्राकृतिक भाषा प्रसंस्करण पसंद है	मुझे | प्राकृतिक | भाषा | प्रसंस्करण | पसंद | है
2	छात्र मशीन लर्निंग सीखते हैं।	छात्र मशीन लर्निंग सीखते हैं।	छात्र मशीन लर्निंग सीखते हैं	छात्र | मशीन | लर्निंग | सीखते | हैं
3	डेटा विज्ञान एक रोचक क्षेत्र है।	डेटा विज्ञान एक रोचक क्षेत्र है।	डेटा विज्ञान एक रोचक क्षेत्र है	डेटा | विज्ञान | एक | रोचक | क्षेत्र | है
4	डेटा विश्लेषण के लिए पायथन उपयोगी है।	डेटा विश्लेषण के लिए पायथन उपयोगी है।	डेटा विश्लेषण के लिए पायथन उपयोगी है	डेटा | विश्लेषण | के | लिए | पायथन | उपयोगी | है
5	कृत्रिम बुद्धिमत्ता दुनिया को बदल रही है।	कृत्रिम बुद्धिमत्ता दुनिया को बदल रही है।	कृत्रिम बुद्धिमत्ता दुनिया को बदल रही है	कृत्रिम | बुद्धिमत्ता | दुनिया | को | बदल | रही | है
6	छात्र सीखने के लिए कंप्यूटर का उपयोग करते हैं।	छात्र सीखने के लिए कंप्यूटर का उपयोग करते हैं।	छात्र सीखने के लिए कंप्यूटर का उपयोग करते हैं	छात्र | सीखने | के | लिए | कंप्यूटर | का | उपयोग | क
7	प्राकृतिक भाषा प्रसंस्करण उपयोगी है।	प्राकृतिक भाषा प्रसंस्करण उपयोगी है।	प्राकृतिक भाषा प्रसंस्करण उपयोगी है	प्राकृतिक | भाषा | प्रसंस्करण | उपयोगी | है
8	मशीन लर्निंग के लिए डेटा आवश्यक है।	मशीन लर्निंग के लिए डेटा आवश्यक है।	मशीन लर्निंग के लिए डेटा आवश्यक है	मशीन | लर्निंग | के | लिए | डेटा | आवश्यक | है
9	हम पायथन का उपयोग करके पाठ का विश्लेषण करते हैं।	हम पायथन का उपयोग करके पाठ का विश्लेषण करते हैं।	हम पायथन का उपयोग करके पाठ का विश्लेषण करते हैं	हम | पायथन | का | उपयोग | करके | पाठ | का | विश्ल
10	संचार के लिए भाषा महत्वपूर्ण है।	संचार के लिए भाषा महत्वपूर्ण है।	संचार के लिए भाषा महत्वपूर्ण है	संचार | के | लिए | भाषा | महत्वपूर्ण | है
11	छात्र पुस्तकालय में किताबें पढ़ते हैं।	छात्र पुस्तकालय में किताबें पढ़ते हैं।	छात्र पुस्तकालय में किताबें पढ़ते हैं	छात्र | पुस्तकालय | में | किताबें | पढ़ते | हैं
12	शिक्षक कठिन अवधारणाओं को समझाते हैं।	शिक्षक कठिन अवधारणाओं को समझाते हैं।	शिक्षक कठिन अवधारणाओं को समझाते हैं	शिक्षक | कठिन | अवधारणाओं | को | समझाते | हैं
13	इंटरनेट उपयोगी जानकारी प्रदान करता है।	इंटरनेट उपयोगी जानकारी प्रदान करता है।	इंटरनेट उपयोगी जानकारी प्रदान करता है	इंटरनेट | उपयोगी | जानकारी | प्रदान | करता | है
14	हम निर्णय लेने के लिए डेटा का उपयोग करते हैं।	हम निर्णय लेने के लिए डेटा का उपयोग करते हैं।	हम निर्णय लेने के लिए डेटा का उपयोग करते हैं	हम | निर्णय | लेने | के | लिए | डेटा | का | उपयोग | क
15	कंप्यूटर बड़ी मात्रा में डेटा संसाधित कर सकता है।	कंप्यूटर बड़ी मात्रा में डेटा संसाधित कर सकता है।	कंप्यूटर बड़ी मात्रा में डेटा संसाधित कर सकता है	कंप्यूटर | बड़ी | मात्रा | में | डेटा | संसाधित | कर | सक
16	छात्र हर दिन प्रोग्रामिंग का अभ्यास करते हैं।	छात्र हर दिन प्रोग्रामिंग का अभ्यास करते हैं।	छात्र हर दिन प्रोग्रामिंग का अभ्यास करते हैं	छात्र | हर | दिन | प्रोग्रामिंग | का | अभ्यास | करते | हैं
17	पायथन एक लोकप्रिय प्रोग्रामिंग भाषा है।	पायथन एक लोकप्रिय प्रोग्रामिंग भाषा है।	पायथन एक लोकप्रिय प्रोग्रामिंग भाषा है	पायथन | एक | लोकप्रिय | प्रोग्रामिंग | भाषा | है
18	डेटा सफाई एक महत्वपूर्ण चरण है।	डेटा सफाई एक महत्वपूर्ण चरण है।	डेटा सफाई एक महत्वपूर्ण चरण है	डेटा | सफाई | एक | महत्वपूर्ण | चरण | है
19	हम पाठ से अनावश्यक शब्द हटाते हैं।	हम पाठ से अनावश्यक शब्द हटाते हैं।	हम पाठ से अनावश्यक शब्द हटाते हैं	हम | पाठ | से | अनावश्यक | शब्द | हटाते | हैं
20	टोकनाइजेशन पाठ को छोटी इकाइयों में विभाजित करता है।	टोकनाइजेशन पाठ को छोटी इकाइयों में विभाजित करता है।	टोकनाइजेशन पाठ को छोटी इकाइयों में विभाजित करता है	टोकनाइजेशन | पाठ | को | छोटी | इकाइयों | में | विभ
21	मॉडल डेटा से पैटर्न सीखता है।	मॉडल डेटा से पैटर्न सीखता है।	मॉडल डेटा से पैटर्न सीखता है	मॉडल | डेटा | से | पैटर्न | सीखता | है
22	मशीन लर्निंग पैटर्न की पहचान कर सकता है।	मशीन लर्निंग पैटर्न की पहचान कर सकता है।	मशीन लर्निंग पैटर्न की पहचान कर सकता है	मशीन | लर्निंग | पैटर्न | की | पहचान | कर | सकता |
23	डीप लर्निंग न्यूरल नेटवर्क का उपयोग करता है।	डीप लर्निंग न्यूरल नेटवर्क का उपयोग करता है।	डीप लर्निंग न्यूरल नेटवर्क का उपयोग करता है	डीप | लर्निंग | न्यूरल | नेटवर्क | का | उपयोग | करता |
24	न्यूरल नेटवर्क में जुड़े हुए नोड होते हैं।	न्यूरल नेटवर्क में जुड़े हुए नोड होते हैं।	न्यूरल नेटवर्क में जुड़े हुए नोड होते हैं	न्यूरल | नेटवर्क | में | जुड़े | हुए | नोड | होते | हैं
25	कृत्रिम बुद्धिमत्ता का उपयोग कई अनुप्रयोगों में किया जाता है।	कृत्रिम बुद्धिमत्ता का उपयोग कई अनुप्रयोगों में किया जाता है।	कृत्रिम बुद्धिमत्ता का उपयोग कई अनुप्रयोगों में किया जाता है	कृत्रिम | बुद्धिमत्ता | का | उपयोग | कई | अनुप्रयोगों |
26	छात्र डेटा विज्ञान सीख रहे हैं।	छात्र डेटा विज्ञान सीख रहे हैं।	छात्र डेटा विज्ञान सीख रहे हैं	छात्र | डेटा | विज्ञान | सीख | रहे | हैं
27	सांख्यिकी हमें डेटा समझने में मदद करती है।	सांख्यिकी हमें डेटा समझने में मदद करती है।	सांख्यिकी हमें डेटा समझने में मदद करती है	सांख्यिकी | हमें | डेटा | समझने | में | मदद | करती | है
28	औसत मान डेटा के केंद्र को दर्शाता है।	औसत मान डेटा के केंद्र को दर्शाता है।	औसत मान डेटा के केंद्र को दर्शाता है	औसत | मान | डेटा | के | केंद्र | को | दर्शाता | है
29	हम माध्य और मानक विचलन की गणना करते हैं।	हम माध्य और मानक विचलन की गणना करते हैं।	हम माध्य और मानक विचलन की गणना करते हैं	हम | माध्य | और | मानक | विचलन | की | गणना | क
30	दृश्यांकन हमें पैटर्न समझने में मदद करता है।	दृश्यांकन हमें पैटर्न समझने में मदद करता है।	दृश्यांकन हमें पैटर्न समझने में मदद करता है	दृश्यांकन | हमें | पैटर्न | समझने | में | मदद | करता | है
31	चार्ट जानकारी को स्पष्ट रूप से प्रस्तुत कर सकते हैं।	चार्ट जानकारी को स्पष्ट रूप से प्रस्तुत कर सकते हैं।	चार्ट जानकारी को स्पष्ट रूप से प्रस्तुत कर सकते हैं	चार्ट | जानकारी | को | स्पष्ट | रूप | से | प्रस्तुत | कर
32	एक डेटासेट में कई अवलोकन होते हैं।	एक डेटासेट में कई अवलोकन होते हैं।	एक डेटासेट में कई अवलोकन होते हैं	एक | डेटासेट | में | कई | अवलोकन | होते | हैं
33	लुप्त मान डेटा विश्लेषण को प्रभावित कर सकते हैं।	लुप्त मान डेटा विश्लेषण को प्रभावित कर सकते हैं।	लुप्त मान डेटा विश्लेषण को प्रभावित कर सकते हैं	लुप्त | मान | डेटा | विश्लेषण | को | प्रभावित | कर | स
34	हमें विश्लेषण से पहले डेटासेट को साफ करना चाहिए।	हमें विश्लेषण से पहले डेटासेट को साफ करना चाहिए।	हमें विश्लेषण से पहले डेटासेट को साफ करना चाहिए	हमें | विश्लेषण | से | पहले | डेटासेट | को | साफ | क
35	असामान्य मान सांख्यिकीय परिणामों को प्रभावित कर सकते हैं।	असामान्य मान सांख्यिकीय परिणामों को प्रभावित कर सकते हैं।	असामान्य मान सांख्यिकीय परिणामों को प्रभावित कर सकते हैं	असामान्य | मान | सांख्यिकीय | परिणामों | को | प्रभावि
36	फीचर चयन अनावश्यक जानकारी को कम करता है।	फीचर चयन अनावश्यक जानकारी को कम करता है।	फीचर चयन अनावश्यक जानकारी को कम करता है	फीचर | चयन | अनावश्यक | जानकारी | को | कम | क
37	एक अच्छा मॉडल नए डेटा पर भी अच्छा प्रदर्शन करना चाहिए।	एक अच्छा मॉडल नए डेटा पर भी अच्छा प्रदर्शन करना चाहिए।	एक अच्छा मॉडल नए डेटा पर भी अच्छा प्रदर्शन करना चाहिए	एक | अच्छा | मॉडल | नए | डेटा | पर | भी | अच्छा |



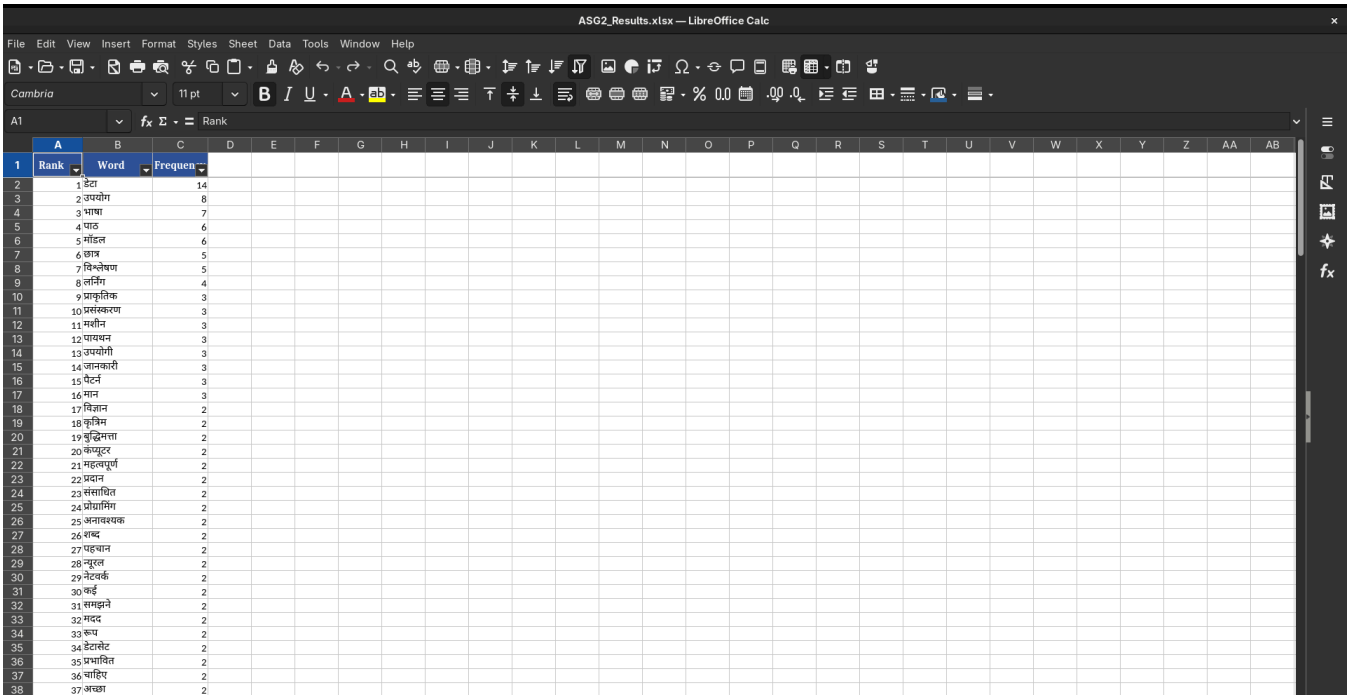
ID	Original Text	Normalized Text	Depunctuated Text	Tokens Before
1	मला नैसर्गिक भाषा प्रक्रिया आवडते.	मला नैसर्गिक भाषा प्रक्रिया आवडते.	मला नैसर्गिक भाषा प्रक्रिया आवडते	मला | नैसर्गिक | भाषा | प्रक्रिया | आवडते
2	विद्यार्थी मशीन लर्निंग शिकतात.	विद्यार्थी मशीन लर्निंग शिकतात.	विद्यार्थी मशीन लर्निंग शिकतात	विद्यार्थी | मशीन | लर्निंग | शिकतात
3	डेटा सायन्स हे एक मनोरंजक क्षेत्र आहे.	डेटा सायन्स हे एक मनोरंजक क्षेत्र आहे.	डेटा सायन्स हे एक मनोरंजक क्षेत्र आहे	डेटा | सायन्स | हे | एक | मनोरंजक | क्षेत्र | आहे
4	डेटा विश्लेषणासाठी पायथन उपयुक्त आहे.	डेटा विश्लेषणासाठी पायथन उपयुक्त आहे.	डेटा विश्लेषणासाठी पायथन उपयुक्त आहे	डेटा | विश्लेषणासाठी | पायथन | उपयुक्त | आहे
5	कृत्रिम बुद्धिमत्ता जग बदलत आहे.	कृत्रिम बुद्धिमत्ता जग बदलत आहे.	कृत्रिम बुद्धिमत्ता जग बदलत आहे	कृत्रिम | बुद्धिमत्ता | जग | बदलत | आहे
6	विद्यार्थी शिकण्यासाठी संगणकाचा वापर करतात.	विद्यार्थी शिकण्यासाठी संगणकाचा वापर करतात.	विद्यार्थी शिकण्यासाठी संगणकाचा वापर करतात	विद्यार्थी | शिकण्यासाठी | संगणकाचा | वापर | करतात
7	नैसर्गिक भाषा प्रक्रिया उपयुक्त आहे.	नैसर्गिक भाषा प्रक्रिया उपयुक्त आहे.	नैसर्गिक भाषा प्रक्रिया उपयुक्त आहे	नैसर्गिक | भाषा | प्रक्रिया | उपयुक्त | आहे
8	मशीन लर्निंगसाठी डेटा आवश्यक आहे.	मशीन लर्निंगसाठी डेटा आवश्यक आहे.	मशीन लर्निंगसाठी डेटा आवश्यक आहे	मशीन | लर्निंगसाठी | डेटा | आवश्यक | आहे
9	आपण पायथनचा वापर करून मजकुराचे विश्लेषण करतो.	आपण पायथनचा वापर करून मजकुराचे विश्लेषण करतो.	आपण पायथनचा वापर करून मजकुराचे विश्लेषण करतो	आपण | पायथनचा | वापर | करून | मजकुराचे | विश्लेषण | करतो
10	संवादासाठी भाषा महत्त्वाची आहे.	संवादासाठी भाषा महत्त्वाची आहे.	संवादासाठी भाषा महत्त्वाची आहे	संवादासाठी | भाषा | महत्त्वाची | आहे
11	विद्यार्थी ग्रंथालयात पुस्तके वाचतात.	विद्यार्थी ग्रंथालयात पुस्तके वाचतात.	विद्यार्थी ग्रंथालयात पुस्तके वाचतात	विद्यार्थी | ग्रंथालयात | पुस्तके | वाचतात
12	शिक्षक कठीण संकल्पना समजावून सांगतात.	शिक्षक कठीण संकल्पना समजावून सांगतात.	शिक्षक कठीण संकल्पना समजावून सांगतात	शिक्षक | कठीण | संकल्पना | समजावून | सांगतात
13	इंटरनेट उपयुक्त माहिती पुरवते.	इंटरनेट उपयुक्त माहिती पुरवते.	इंटरनेट उपयुक्त माहिती पुरवते	इंटरनेट | उपयुक्त | माहिती | पुरवते
14	आपण निर्णय घेण्यासाठी डेटाचा वापर करतो.	आपण निर्णय घेण्यासाठी डेटाचा वापर करतो.	आपण निर्णय घेण्यासाठी डेटाचा वापर करतो	आपण | निर्णय | घेण्यासाठी | डेटाचा | वापर | करतो
15	संगणक मोठ्या प्रमाणात डेटावर प्रक्रिया करू शकतो.	संगणक मोठ्या प्रमाणात डेटावर प्रक्रिया करू शकतो.	संगणक मोठ्या प्रमाणात डेटावर प्रक्रिया करू शकतो	संगणक | मोठ्या | प्रमाणात | डेटावर | प्रक्रिया | करू | शकतो
16	विद्यार्थी दररोज प्रोग्रामिंगचा सराव करतात.	विद्यार्थी दररोज प्रोग्रामिंगचा सराव करतात.	विद्यार्थी दररोज प्रोग्रामिंगचा सराव करतात	विद्यार्थी | दररोज | प्रोग्रामिंगचा | सराव | करतात
17	पायथन ही एक लोकप्रिय प्रोग्रामिंग भाषा आहे.	पायथन ही एक लोकप्रिय प्रोग्रामिंग भाषा आहे.	पायथन ही एक लोकप्रिय प्रोग्रामिंग भाषा आहे	पायथन | ही | एक | लोकप्रिय | प्रोग्रामिंग | भाषा | आहे
18	डेटा स्वच्छता ही एक महत्त्वाची पायरी आहे.	डेटा स्वच्छता ही एक महत्त्वाची पायरी आहे.	डेटा स्वच्छता ही एक महत्त्वाची पायरी आहे	डेटा | स्वच्छता | ही | एक | महत्त्वाची | पायरी | आहे
19	आपण मजकुरातून अनावश्यक शब्द काढून टाकतो.	आपण मजकुरातून अनावश्यक शब्द काढून टाकतो.	आपण मजकुरातून अनावश्यक शब्द काढून टाकतो	आपण | मजकुरातून | अनावश्यक | शब्द | काढून | टाकतो
20	टोकनायझेशन मजकुराचे लहान घटकांमध्ये विभाजन करते.	टोकनायझेशन मजकुराचे लहान घटकांमध्ये विभाजन करते.	टोकनायझेशन मजकुराचे लहान घटकांमध्ये विभाजन करते	टोकनायझेशन | मजकुराचे | लहान | घटकांमध्ये | विभाजन | करते
21	मॉडेल डेटामधून नमुने शिकते.	मॉडेल डेटामधून नमुने शिकते.	मॉडेल डेटामधून नमुने शिकते	मॉडेल | डेटामधून | नमुने | शिकते
22	मशीन लर्निंग नमुने ओळखू शकते.	मशीन लर्निंग नमुने ओळखू शकते.	मशीन लर्निंग नमुने ओळखू शकते	मशीन | लर्निंग | नमुने | ओळखू | शकते
23	डीप लर्निंग न्यूरल नेटवर्कचा वापर करते.	डीप लर्निंग न्यूरल नेटवर्कचा वापर करते.	डीप लर्निंग न्यूरल नेटवर्कचा वापर करते	डीप | लर्निंग | न्यूरल | नेटवर्कचा | वापर | करते
24	न्यूरल नेटवर्कमध्ये जोडलेले नोड असतात.	न्यूरल नेटवर्कमध्ये जोडलेले नोड असतात.	न्यूरल नेटवर्कमध्ये जोडलेले नोड असतात	न्यूरल | नेटवर्कमध्ये | जोडलेले | नोड | असतात
25	कृत्रिम बुद्धिमत्तेचा वापर अनेक अनुप्रयोगांमध्ये केला जातो.	कृत्रिम बुद्धिमत्तेचा वापर अनेक अनुप्रयोगांमध्ये केला जातो.	कृत्रिम बुद्धिमत्तेचा वापर अनेक अनुप्रयोगांमध्ये केला जातो	कृत्रिम | बुद्धिमत्तेचा | वापर | अनेक | अनुप्रयोगांमध्ये | केला | जातो
26	विद्यार्थी डेटा सायन्स शिकत आहेत.	विद्यार्थी डेटा सायन्स शिकत आहेत.	विद्यार्थी डेटा सायन्स शिकत आहेत	विद्यार्थी | डेटा | सायन्स | शिकत | आहेत
27	सांख्यिकी आपल्याला डेटा समजून घेण्यास मदत करते.	सांख्यिकी आपल्याला डेटा समजून घेण्यास मदत करते.	सांख्यिकी आपल्याला डेटा समजून घेण्यास मदत करते	सांख्यिकी | आपल्याला | डेटा | समजून | घेण्यास | मदत | करते
28	सरासरी मूल्य डेटाचे केंद्र दर्शवते.	सरासरी मूल्य डेटाचे केंद्र दर्शवते.	सरासरी मूल्य डेटाचे केंद्र दर्शवते	सरासरी | मूल्य | डेटाचे | केंद्र | दर्शवते
29	आपण सरासरी आणि प्रमाणित विचलन मोजतो.	आपण सरासरी आणि प्रमाणित विचलन मोजतो.	आपण सरासरी आणि प्रमाणित विचलन मोजतो	आपण | सरासरी | आणि | प्रमाणित | विचलन | मोजतो
30	दृश्यांकन आपल्याला नमुने समजून घेण्यास मदत करते.	दृश्यांकन आपल्याला नमुने समजून घेण्यास मदत करते.	दृश्यांकन आपल्याला नमुने समजून घेण्यास मदत करते	दृश्यांकन | आपल्याला | नमुने | समजून | घेण्यास | मदत | करते
31	चार्ट माहिती स्पष्टपणे सादर करू शकतात.	चार्ट माहिती स्पष्टपणे सादर करू शकतात.	चार्ट माहिती स्पष्टपणे सादर करू शकतात	चार्ट | माहिती | स्पष्टपणे | सादर | करू | शकतात
32	डेटासेटमध्ये अनेक निरीक्षणे असतात.	डेटासेटमध्ये अनेक निरीक्षणे असतात.	डेटासेटमध्ये अनेक निरीक्षणे असतात	डेटासेटमध्ये | अनेक | निरीक्षणे | असतात
33	गहाळ मूल्ये डेटा विश्लेषणावर परिणाम करू शकतात.	गहाळ मूल्ये डेटा विश्लेषणावर परिणाम करू शकतात.	गहाळ मूल्ये डेटा विश्लेषणावर परिणाम करू शकतात	गहाळ | मूल्ये | डेटा | विश्लेषणावर | परिणाम | करू | शकतात
34	विश्लेषणापूर्वी आपल्याला डेटासेट स्वच्छ करणे आवश्यक आहे.	विश्लेषणापूर्वी आपल्याला डेटासेट स्वच्छ करणे आवश्यक आहे.	विश्लेषणापूर्वी आपल्याला डेटासेट स्वच्छ करणे आवश्यक आहे	विश्लेषणापूर्वी | आपल्याला | डेटासेट | स्वच्छ | करणे | आवश्यक | आहे
35	असामान्य मूल्ये सांख्यिकीय परिणामांवर परिणाम करू शकतात.	असामान्य मूल्ये सांख्यिकीय परिणामांवर परिणाम करू शकतात.	असामान्य मूल्ये सांख्यिकीय परिणामांवर परिणाम करू शकतात	असामान्य | मूल्ये | सांख्यिकीय | परिणामांवर | परिणाम | करू | शकतात
36	फीचर निवड अनावश्यक माहिती कमी करते.	फीचर निवड अनावश्यक माहिती कमी करते.	फीचर निवड अनावश्यक माहिती कमी करते	फीचर | निवड | अनावश्यक | माहिती | कमी | करते
37	चांगल्या मॉडेलने नवीन डेटावरही चांगली कामगिरी केली पाहिजे.	चांगल्या मॉडेलने नवीन डेटावरही चांगली कामगिरी केली पाहिजे.	चांगल्या मॉडेलने नवीन डेटावरही चांगली कामगिरी केली पाहिजे	चांगल्या | मॉडेलने | नवीन | डेटावरही | चांगली | कामगिरी | केली | पाहिजे



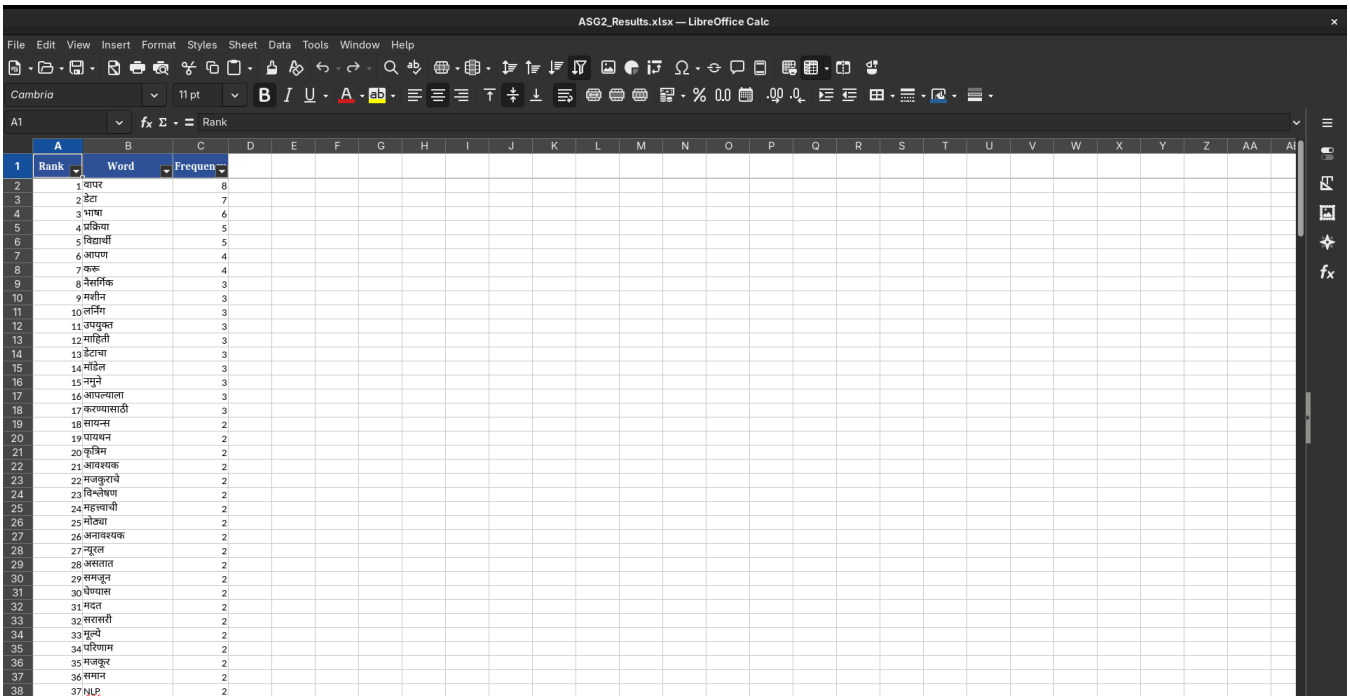
Language	Source Sentences	Total Tokens (Before)	Unique Tokens (Before)	Total Tokens (After)	Unique Tokens (After)	Tokens Removed	Unique Removed	Post-Stemming Tot	Post-Stemming Unique	Vocabulary Ratio (After)
English	50	297	165	224	144	73	21	224	127	0.6429
Hindi	50	407	168	225	135	182	33			0.6
Marathi	50	297	190	242	170	55	20			0.7025



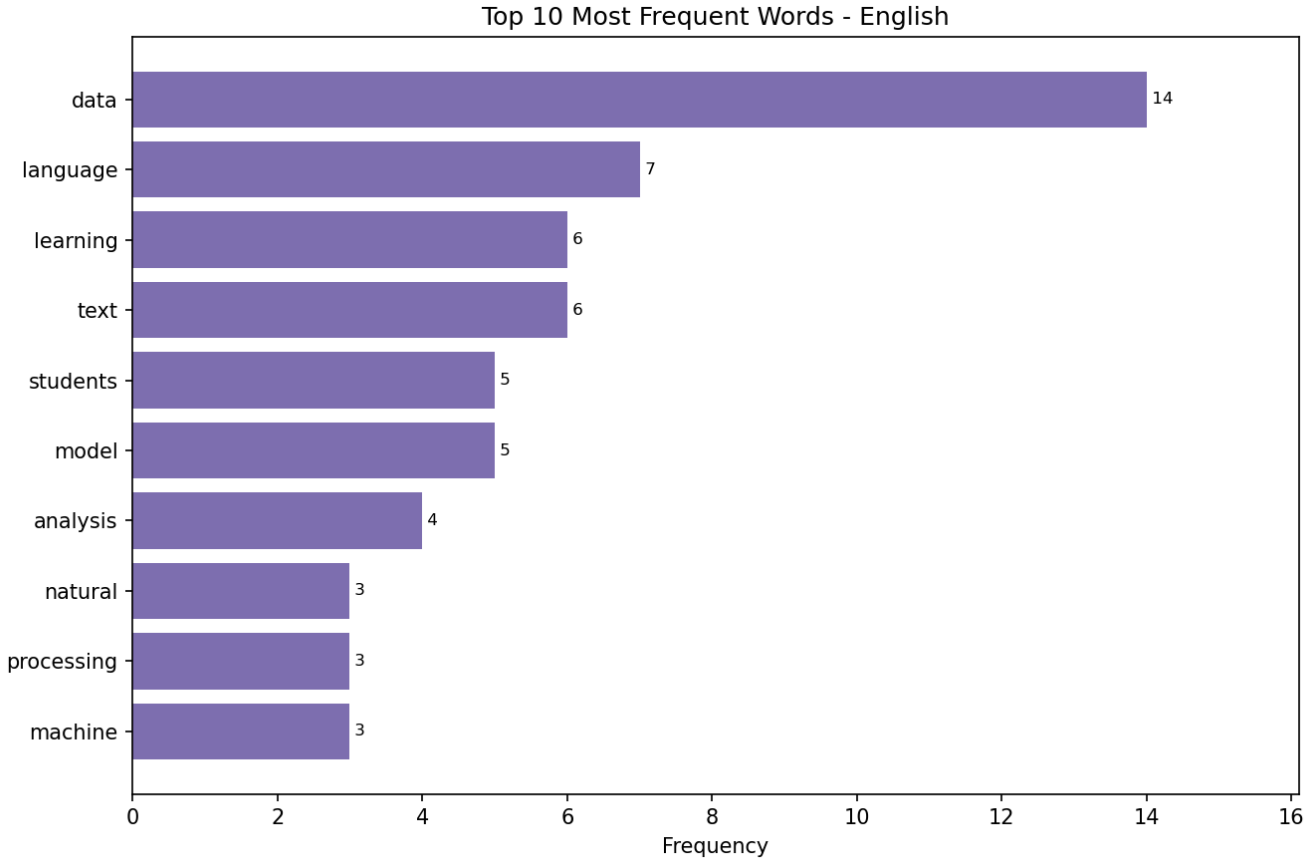
Rank	Word	Frequen	Stem	Stem Frequen
1	data	14	data	14
2	language	7	languag	7
3	learning	6	learn	8
4	text	6	text	6
5	students	5	student	5
6	model	5	model	6
7	analysis	4	analysi	4
8	natural	3	natur	3
9	processing	3	process	5
10	machine	3	machin	3
11	python	3	python	3
12	useful	3	use	11
13	use	3	use	11
14	information	3	inform	3
15	words	3	word	5
16	patterns	3	pattern	3
17	used	3	use	11
18	science	2	scienc	2
19	artificial	2	artifici	2
20	intelligence	2	intellig	2
21	important	2	import	2
22	process	2	process	5
23	large	2	larg	2
24	programming	2	program	2
25	unnecessary	2	unnecessari	2
26	neural	2	neural	2
27	contains	2	contain	2
28	many	2	mani	2
29	applications	2	applic	2
30	helps	2	help	2
31	us	2	us	2
32	understand	2	understand	2
33	dataset	2	dataset	2
34	evaluate	2	evalu	2
35	word	2	word	5
36	similar	2	similar	2
37	nlp	2	nlp	2

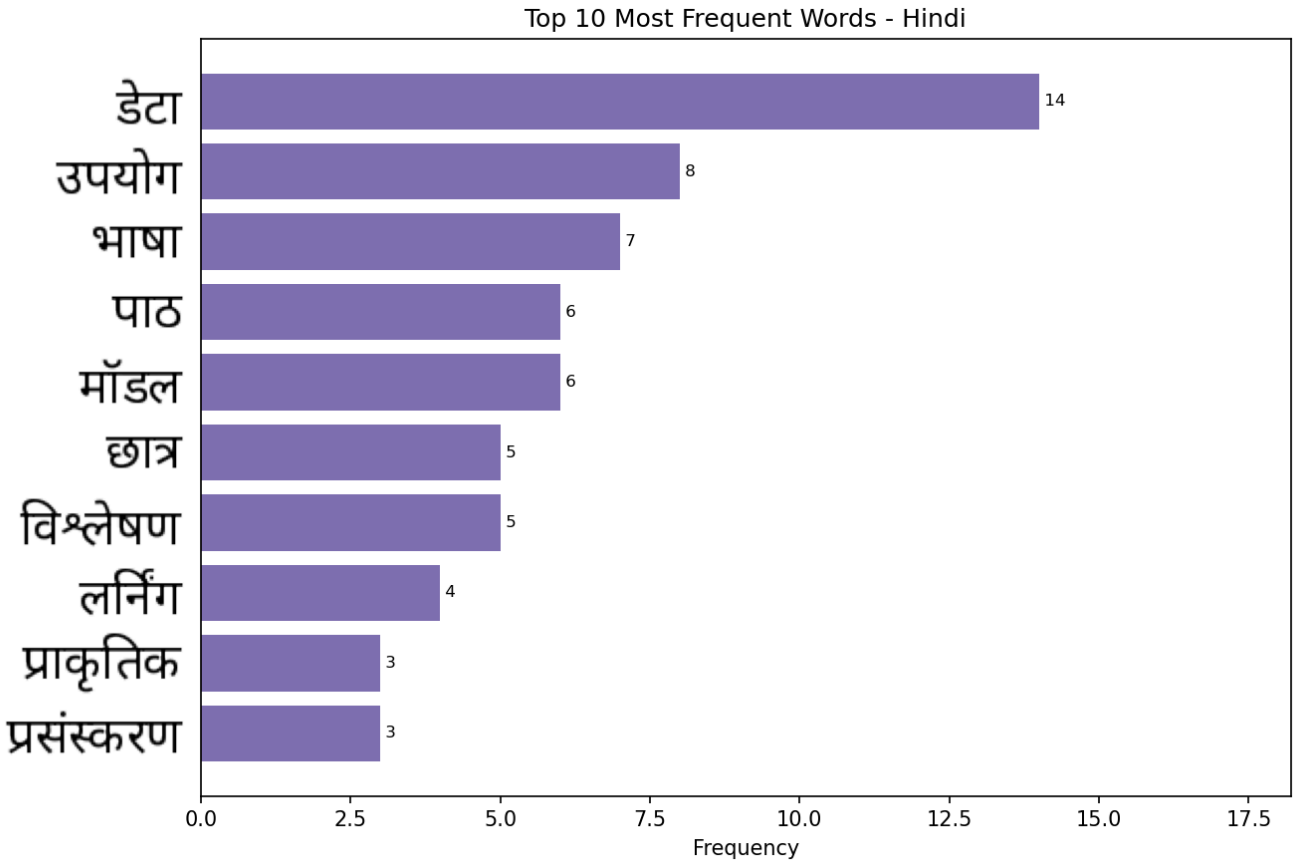


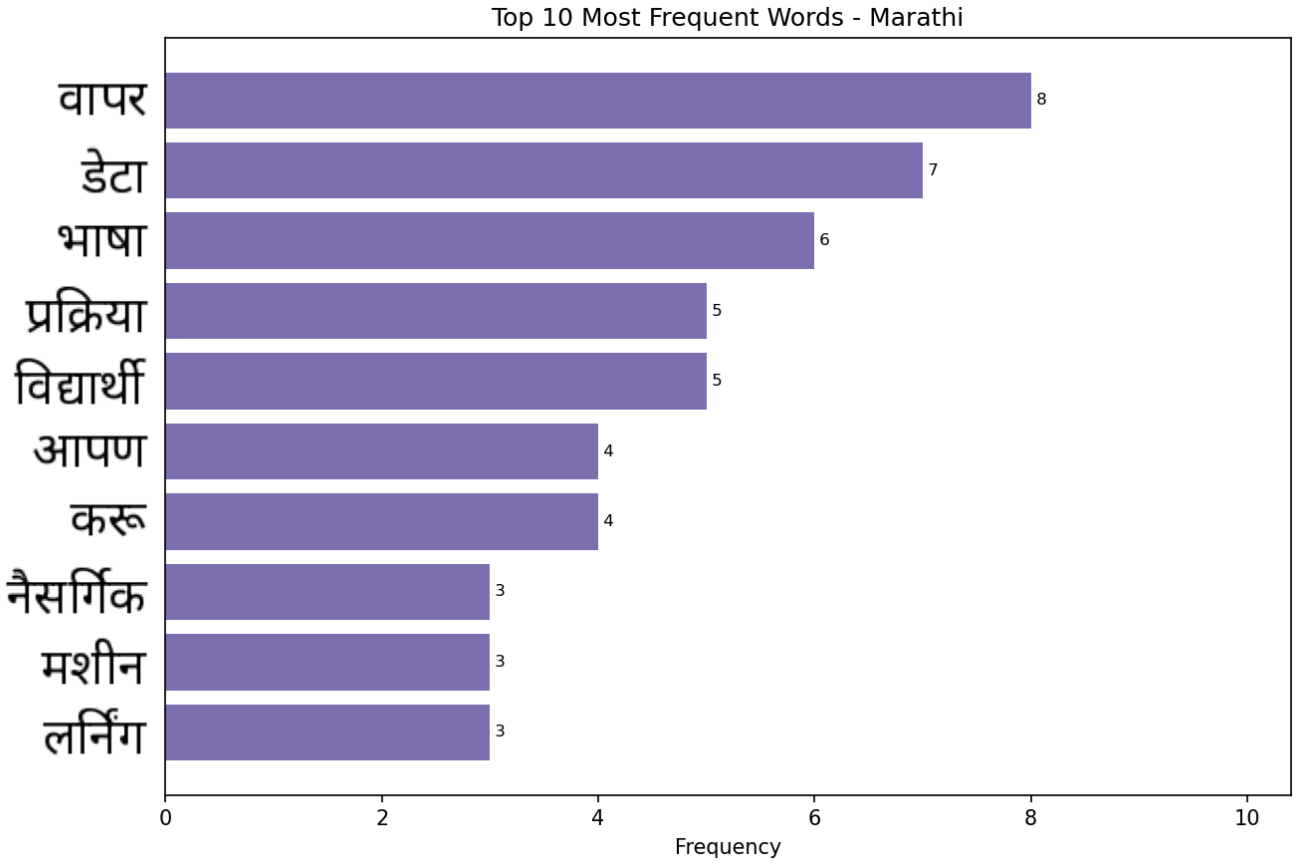
Rank	Word	Frequen
1	डेटा	14
2	उपयोग	8
3	भाषा	7
4	पाठ	6
5	मॉडल	6
6	छात्र	5
7	विश्लेषण	5
8	लर्निंग	4
9	प्राकृतिक	3
10	प्रसंस्करण	3
11	मशीन	3
12	पायथन	3
13	उपयोगी	3
14	जानकारी	3
15	पैटर्न	3
16	मान	3
17	विज्ञान	2
18	कृत्रिम	2
19	बुद्धिमत्ता	2
20	कंप्यूटर	2
21	महत्वपूर्ण	2
22	प्रदान	2
23	संसाधित	2
24	प्रोग्रामिंग	2
25	अनावश्यक	2
26	शब्द	2
27	पहचान	2
28	न्यूरल	2
29	नेटवर्क	2
30	कई	2
31	समझने	2
32	मदद	2
33	रूप	2
34	डेटासेट	2
35	प्रभावित	2
36	चाहिए	2
37	अच्छा	2

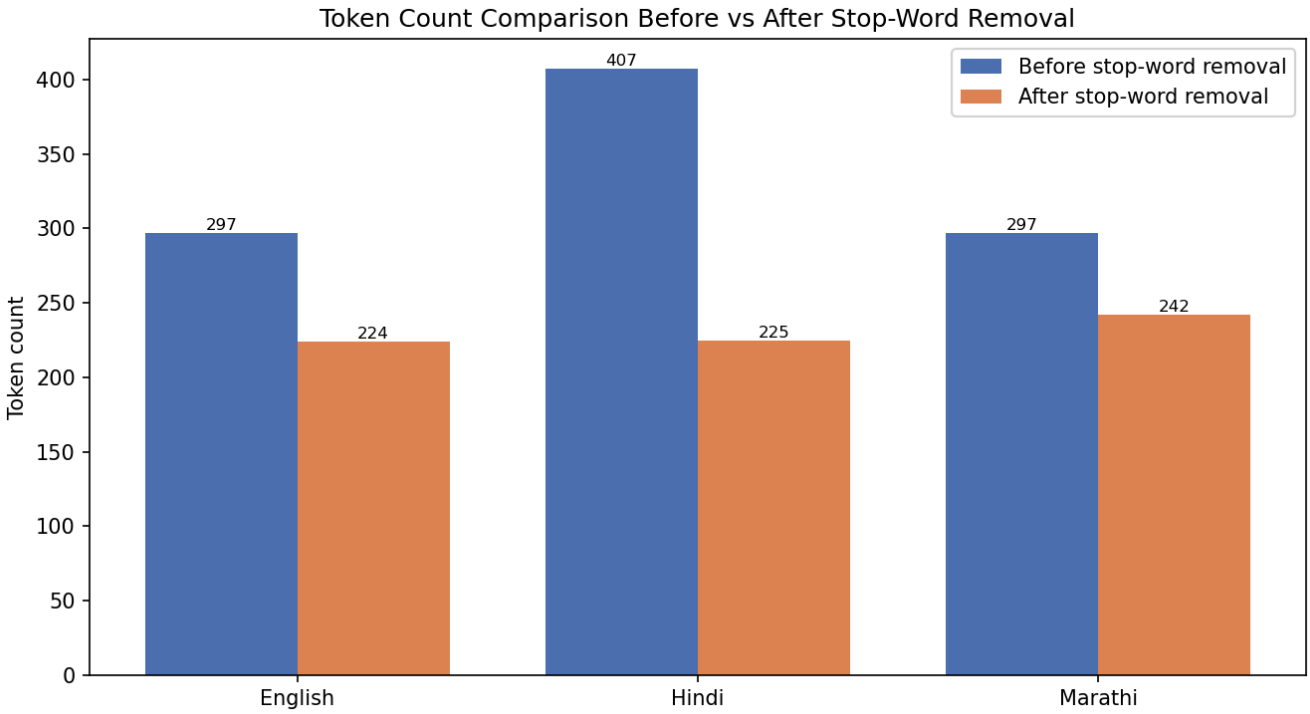


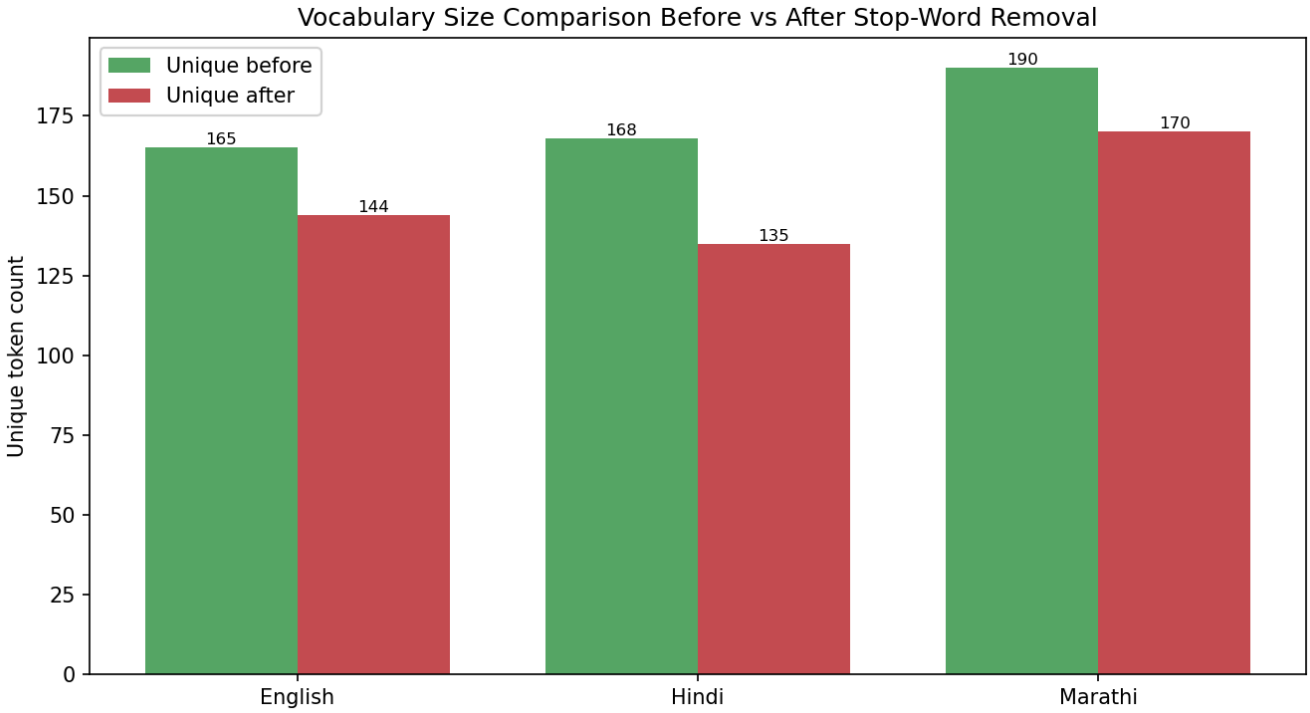
Rank	Word	Frequen
1	वापर	8
2	डेटा	7
3	भाषा	6
4	प्रक्रिया	5
5	विद्यार्थी	5
6	आपण	4
7	करू	4
8	नैसर्गिक	3
9	मशीन	3
10	लर्निंग	3
11	उपयुक्त	3
12	माहिती	3
13	डेटाचा	3
14	मॉडेल	3
15	नमुने	3
16	आपल्याला	3
17	करण्यासाठी	3
18	सायन्स	2
19	पायथन	2
20	कृत्रिम	2
21	आवश्यक	2
22	मजकुराचे	2
23	विश्लेषण	2
24	महत्त्वाची	2
25	मोठ्या	2
26	अनावश्यक	2
27	न्यूरल	2
28	असतात	2
29	समजून	2
30	घेण्यास	2
31	मदत	2
32	ससासरी	2
33	मूल्ये	2
34	परिणाम	2
35	मजकूर	2
36	समान	2
37	NLP	2




Top 10 Most Frequent Words - Hindi
डेटा
उपयोग
भाषा
पाठ
मॉडल
छात्र
विश्लेषण
लर्निंग
प्राकृतिक
प्रसंस्करण
14
8
7
6
6
5
5
4
3
3
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Frequency


Top 10 Most Frequent Words - Marathi
वापर
डेटा
भाषा
प्रक्रिया
विद्यार्थी
आपण
करू
नैसर्गिक
मशीन
लर्निंग
8
7
6
5
5
4
4
3
3
3
0
2
4
6
8
10
Frequency





12. Observations and Comparative Analysis

- All three languages were successfully processed using Python-based NLP techniques.
- The dataset contains 50 sentences for each language.
- English contained 297 tokens and 165 unique tokens before stop-word removal.
- Hindi contained 407 tokens and 168 unique tokens before stop-word removal.
- Marathi contained 297 tokens and 190 unique tokens before stop-word removal.

- Hindi requires Unicode-aware tokenization because it uses the Devanagari script.
- Marathi also uses the Devanagari script, but its vocabulary and word forms differ from Hindi.
- English has extensive NLP resources, including NLTK stop-word lists and the Porter Stemmer.
- Basic stemming was applied only to English in this implementation.
- Frequency analysis showed that domain-specific terms such as **data, language, learning, model, भाषा, डेटा, भाषा, प्रक्रिया** occur frequently.
- The same concepts can have different token counts across languages because of differences in grammar, morphology and word formation.
- Language-specific NLP resources are therefore important for obtaining better processing results.

14. Language-specific Challenges English

English has relatively extensive NLP resources and standardized tokenization methods. However, stemming can sometimes produce root-like forms that are not actual dictionary words.

Hindi

Hindi uses the Devanagari script and has rich morphological variation. Word forms can change according to gender, number, tense and grammatical context. Therefore, simple tokenization and manually selected stop-word lists may not provide complete linguistic analysis.

Marathi

Marathi also uses the Devanagari script and has rich morphology. Different grammatical forms of words may appear as separate tokens. A more advanced Marathi NLP system would require language-specific morphological resources and models.

General Multilingual Challenges

- Different scripts
- Different grammatical structures
- Morphological variation
- Different stop-word lists
- Limited resources for some languages
- Different stemming and lemmatization requirements
- Ambiguity in word meanings
- Different NLP model quality across languages

The template specifically asks this section to discuss tokenization, morphology, stop-word resources, stemming/lemmatization, ambiguity and model availability.

15. Conclusion

In this assignment, fundamental NLP processing was performed on English, Hindi and Marathi text using a common multilingual dataset. The main preprocessing operations included normalization, tokenization, punctuation handling, stop-word removal and frequency analysis.

English stemming was performed using the Porter Stemmer, while stemming was not applied to Hindi and Marathi in this basic implementation. The experiment demonstrated that NLP processing differs between languages because of differences in scripts, morphology, vocabulary and available language resources.

Frequency analysis also demonstrated that commonly occurring words differ across the three languages. Overall, the assignment shows the importance of language-specific preprocessing and resources when developing multilingual NLP applications.

16. Viva Questions

1. What is tokenization and why can it differ between languages?

Answer: Tokenization is the process of dividing text into smaller units called tokens. It can differ between languages because languages have different scripts, word boundaries, punctuation and grammatical structures.

2. What is the difference between stemming and lemmatization?

Answer: **Stemming** removes parts of a word to produce a root-like form, while **lemmatization** uses linguistic information to produce the correct dictionary base form.

Example:

studies → studi can be a stemming result, while lemmatization may produce study.

3. Why are language-specific NLP resources required?

Answer: Different languages have different grammar, vocabulary, scripts and morphological rules. Language-specific resources such as stop-word lists, tokenizers, stemmers and trained models improve processing quality.

4. What are stop words? Are they always safe to remove?

Answer: Stop words are common words such as "the", "is", "and" that may have limited value for some NLP tasks. They are not always safe to remove because they can carry important meaning in tasks such as sentiment analysis, question answering and language modeling.

5. What is POS tagging?

Answer: POS tagging assigns a grammatical category such as noun, verb, adjective or adverb to each word in a sentence.

6. What is Named Entity Recognition?

Answer: Named Entity Recognition, or NER, identifies entities such as people, organizations, locations, dates and other named entities in text.

7. What challenges can occur while processing morphologically rich languages?

Answer: There can be many word forms for the same basic word, making tokenization, stemming, lemmatization and vocabulary analysis more difficult.

8. Why can the same NLP library provide different quality for different languages?

Answer: NLP libraries depend on language-specific datasets, models and linguistic resources. A library may have extensive resources for one language but limited resources for another language, resulting in different processing quality.

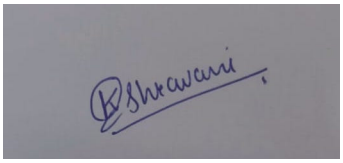
17. References

- Bird, Steven, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O'Reilly Media.
- Jurafsky, Daniel and James H. Martin. *Speech and Language Processing*.
- NLTK Documentation – Natural Language Toolkit.
- Python Documentation – Text processing and Unicode support.

18. Faculty Evaluation

Evaluation Parameter	Marks	Remarks
Understanding of concept	--/5	
Correctness of preprocessing	--/5	
Multilingual implementation	--/5	
Results and analysis	--/5	
Documentation	--/5	
Viva / demonstration	--/5	
Total	--/30	

Student Signature:



Faculty Signature: _____

Date: _____